

INSURMINDS

Plataforma inteligente para análise e comparação de apólices D&O

Relatório técnico | Projeto Final I2A2 2026

Revisado em: 06/10/2026

MVP local com extração estruturada por IA, evidências por página e comparação documental reproduzível.

Equipe InsurMinds: Victor Hugo Araujo, João Carlos Mendonça, Adriéli Zacharias e Bruno Veiga.

Situação da validação: dois PDFs fictícios foram analisados pelo Gemini 3.8 Flash: 16 critérios com evidências verificadas em cada documento; comparação com 10 diferenças e exportações PDF/JSON aprovadas. A interpretação dos valores é conferida pelo usuário. O repositório está público.

Arquitetura do InsurMinds

O InsurMinds é um MVP local para leitura e comparação documental de apólices D&O. A interface apresenta 16 critérios, o conteúdo extraído e as evidências. O usuário valida a interpretação. A solução não produz ranking de seguradoras ou recomendação de contratação.

Componentes e fluxo

```
Interface React
  API Starlette
    Recepção e leitura PDF / imagem
    Extração multimodal Gemini
    Validação de dados e evidências
  SQLite e arquivos locais
    Comparação de critérios
    PDF / JSON e consulta contextual
```

O frontend usa React 19, TypeScript, Vite, Tailwind CSS 4, shadcn/ui com Radix e Lucide. A fonte DM Sans é distribuída localmente. A interface permite navegação por teclado, diálogos com controle e retorno de foco, estados de erro, busca, filtros, seleção limitada e adaptação a dispositivos móveis. Tokens e padrões visuais estão em DESIGN.md e os componentes reutilizáveis em src/components/ui/.

A API usa Starlette, uvicorn, Pydantic, SQLite e HTTPX. O servidor tem um único processo e até duas tarefas simultâneas de extração. A fila em memória aceita até seis tarefas pendentes ou ativas. Reinícios marcam trabalhos incompletos como falha, permitindo nova tentativa. Não há fila distribuída nem promessa de alta disponibilidade.

Componentes especializados

O termo agente designa responsabilidades do pipeline, não uma equipe de agentes autônomos com ferramentas abertas. A extração e a consulta usam IA generativa; a recepção, a validação, a comparação e o relatório são determinísticos.

1. Recepção (backend/app.py): recebe o arquivo, valida conteúdo, limita tamanho e atribui identificador UUID. Nomes enviados pelo usuário não determinam caminhos de armazenamento.
2. Leitura (backend/documents.py): extrai texto por página. Páginas com menos de 80 caracteres são rasterizadas. Imagens PNG, JPEG e WebP são normalizadas para leitura visual.
3. Extração (backend/agents.py): divide o documento em blocos com páginas originais, envia texto e imagens ao Google GenAI e solicita JSON estruturado. backend/checkpoints.py salva respostas concluídas para retomada local. A consolidação determinística preserva valores distintos e suas evidências, sem decidir qual condição prevalece.
4. Estruturação e validação (backend/models.py, backend/agents.py): valida tipos, classificação D&O, chaves únicas, páginas e presença literal das citações no texto.
5. Comparação (backend/agents.py): compara os mesmos 16 campos entre dois a quatro documentos. O resultado distingue diferença textual, igualdade textual e dado ausente.
6. Relatório (backend/reports.py): gera PDF com tabela comparativa, limitações e trechos de origem. JSON preserva o resultado estruturado.
7. Consulta (backend/app.py): usa GenerateContent para responder perguntas sobre fatos já extraídos. O prompt solicita páginas e admite ausência de informação. As citações da resposta livre não têm validador automático.

Contrato de dados

Cada apólice contém ID, nome, arquivo, status, datas UTC, modelo configurado, modelos efetivamente usados, progresso por bloco, indicador de demonstração, páginas, fatos e avisos. Cada fato contém key, value, quote, page, evidence_status, uma lista evidence, versões com suas próprias evidências em variants e needs_review. quote/page preservam a primeira referência para compatibilidade com documentos antigos.

Os estados das evidências são verified (trecho localizado por comparação normalizada de espaços e caixa), visual_review (leitura multimodal que exige conferência visual) e missing. O estado verified comprova apenas presença textual, não a correção jurídica ou lógica do valor extraído.

Dados sem trecho ou sem página válida são descartados. Se a página contém texto e o trecho não aparece, o valor é descartado. Em páginas rasterizadas, uma citação não encontrada no texto permanece marcada para revisão visual. A ausência de informação nunca se converte em exclusão ou cobertura contratada.

SQLite mantém duas tabelas, policies e comparisons, com identificadores e documentos JSON. As comparações guardam uma fotografia dos fatos usados, preservando o resultado histórico. O modo WAL facilita leituras concorrentes. As conexões são fechadas explicitamente.

Decisões arquiteturais

SQLite elimina a instalação de um banco separado e é suficiente para o workspace local. JSON preserva o contrato aninhado sem migrações prematuras; consultas analíticas em escala exigiriam tabelas normalizadas.

A leitura híbrida reduz o envio de imagens em PDFs pesquisáveis. A heurística de 80 caracteres pode falhar em páginas com texto decorativo ou OCR ruim. Cada bloco contém no máximo 60 mil caracteres, 20 páginas e 4 imagens. Páginas com texto acima do limite são divididas com sobreposição de 500 caracteres, mantendo o número original; nenhum trecho é cortado silenciosamente.

Uma chamada estruturada por bloco permite analisar documentos longos. O modelo padrão é gemini-3.8-flash, configurável por GEMINI_MODEL, com alternativa gemini-3.7-flash em GEMINI_FALLBACK_MODELS. Deixar a variável vazia desativa a alternância. A disponibilidade e as cotas dependem da conta. A comparação determinística ignora a numeração das páginas ao comparar valores, mantém diferenças reproduzíveis e evita que uma segunda geração invente um ranking.

As chamadas têm timeout de 90 segundos e até três tentativas por modelo, com espera exponencial e jitter para erros transitórios. As repetições internas do SDK são desativadas para evitar multiplicação de tentativas. Um fluxo serializado de chamadas respeita um intervalo mínimo de 15 segundos, configurável por GEMINI_REQUEST_INTERVAL. A alternância ocorre após indisponibilidade ou modelo não encontrado, nunca para contornar cotas ou erros de chave. Checkpoints gravados atomicamente usam hash do conteúdo do bloco, prompt, schema e modelos. Reprocessamentos e reinícios reutilizam os blocos concluídos; não há garantia de idempotência no provedor para chamadas interrompidas antes do checkpoint.

Limites e proteção de dados

O MVP aceita até 20 MB, 300 páginas PDF e 2 milhões de caracteres por documento. Páginas visuais são limitadas por bloco. PDF criptografado e formatos não reconhecidos são rejeitados. Um documento deve representar uma única apólice e suas condições coerentes.

A chave fica no .env do servidor e não é enviada ao navegador. Documentos são dados não confiáveis para o prompt. Não são disponibilizadas ferramentas de execução ao modelo. O servidor não inclui autenticação e deve operar em loopback, em um único processo. Embora o repositório seja público, a aplicação não deve ser exposta na Internet sem autenticação, isolamento por usuário, quotas, limite de requisições, políticas de retenção e revisão de segurança.

O código não configura uma política de retenção zero no provedor. O tratamento do conteúdo enviado depende das condições e configurações da conta Gemini. Arquivos originais, textos e rasterizações ficam em data/; essa pasta não entra no repositório ou no ZIP. O MVP não implementa criptografia em repouso nem exclusão pela interface.

Condições gerais podem descrever coberturas não contratadas. Evidências múltiplas e versões por bloco preservam passagens espalhadas, mas não comprovam que o resumo é completo ou correto. Valores equivalentes com redações diferentes aparecem como diferenças textuais. Não há normalização atuarial, jurídica ou cambial; condições que dependem de passagens em outros blocos precisam de revisão.

Validação funcional

Testes automatizados cobrem leitura de PDF e imagem, PDFs criptografados, limites, dados ausentes, evidências falsas, persistência, comparação e exportação. O teste automatizado de upload usa um provedor simulado. A execução real de 05/10/2026 com Gemini 3.8 Flash concluiu os dois PDFs fictícios: 16 critérios com evidências textuais verificadas em cada documento, 10 diferenças entre 16 campos e nenhuma ausência. As exportações PDF e JSON passaram. O registro está em Projeto_Final_Artefatos/Validacao_IA_Exemplos.json. Foram aprovados 32 testes Python e um teste Node de upload, além do build e da verificação de interface em desktop e celular. A validação utiliza os documentos fictícios autorais do projeto. A ferramenta confere a origem textual das informações; a interpretação contratual é conferida pelo usuário.

Fontes

- Projeto Final I2A2 2026: leitura e comparação de apólices com IA generativa.
- Google Gemini API, structured output: <https://ai.google.dev/gemini-api/docs/structured-output>
- Google Gemini API, multimodal: <https://ai.google.dev/gemini-api/docs/vision>
- Documentos de demonstração: criação sintética autoral do projeto em backend/demo.py. Aurora, Vértice e Horizonte são nomes fictícios, sem relação com contratos reais.
- Repositório público: <https://github.com/vicTmm/i2a2-desafio-final>.